

Executive Technical Summary: WAZE


The Nuts and Bolts of Machine Learning

Executive Summary: Business Context, KPIs & Strategic Impact / Contexto de Negocio, KPIs e Impacto Estratégico




- EN:
- We are asked to build and evaluate tree-based machine learning models (Random Forest and XGBoost) to classify whether a Waze user will be retained or churned.
 - The success metric for the business objective is reducing the overall churn rate and optimizing marketing spend by targeting only at-risk drivers.
 - Numerically, since the cost of losing a user silently is very high (loss of Customer Lifetime Value), Recall is a primary metric to optimize, balanced by the F1-Score to maintain overall classification stability.

- ES:
- Se nos pide construir y evaluar modelos de aprendizaje automático basados en árboles (Random Forest y XGBoost) para clasificar si un usuario de Waze se mantendrá activo o abandonará la aplicación.
 - La métrica de éxito para el objetivo del negocio es reducir la tasa de abandono general y optimizar el gasto de marketing dirigiéndose solo a los conductores en riesgo.
 - Numéricamente, dado que el costo de perder a un usuario de forma silenciosa es muy alto (pérdida del valor de vida del cliente), Recall es la métrica principal a optimizar, equilibrada con el F1-Score para mantener la estabilidad global de la clasificación.



- EN:
- The ethical implications center on user data privacy regarding driving behavior and aggregation. The data represents monthly aggregated usage (sessions, driving days, kilometers) and does not track real-time locations or precise coordinates to prevent individual tracking.
 - The consequences of errors involve economic trade-offs (wasted retention budgets) or market share loss, rather than physical safety risks or discriminatory biases.

- ES:
- Las implicaciones éticas se centran en la privacidad de los datos de comportamiento de conducción y su agregación. Los datos representan el uso agregado mensual (sesiones, días de conducción, kilómetros) y no rastrean ubicaciones en tiempo real ni coordenadas precisas para evitar el seguimiento individual.
 - Las consecuencias de los errores implican balances económicos (desperdicio de presupuestos de retención) o pérdida de cuota de mercado, en lugar de riesgos de seguridad física o sesgos discriminatorios.



- EN:
- A **False Negative (FN)** means the model predicts a user will stay, but they actually churn. The consequence is that Waze fails to engage the user with an incentive, resulting in a silent loss of a customer to competitors.
 - A **False Positive (FP)** occurs when the model misclassifies a loyal user as someone about to churn. The effect is an inefficient allocation of resources, wasting financial and marketing budgets on users who intended to stay anyway.

- ES:
- Un **Falso Negativo (FN)** significa que el modelo predice que un usuario se quedará, pero en realidad abandona la app. La consecuencia es que Waze pierde la oportunidad de ofrecer un incentivo, resultando en la pérdida silenciosa del cliente ante la competencia.
 - Un **Falso Positivo (FP)** ocurre cuando el modelo clasifica erróneamente a un usuario leal como alguien a punto de abandonar la app. El efecto es una asignación ineficiente de recursos, desperdiciando presupuesto financiero y de marketing en usuarios que de todos modos planeaban quedarse.



- EN:
- I would proceed by building tree-based ensemble models (Random Forest and XGBoost), prioritizing Recall during cross-validation (refit="recall") to minimize dangerous False Negatives.
 - To mitigate False Positives, I will implement a probabilistic threshold queue: users with critical risk (>75%) get automated high-value retention offers, while the "gray zone" (45%-75%) receives organic app notifications to drive engagement without burning marketing budget.

- ES:
- Procederé construyendo modelos de ensamble basados en árboles (Random Forest y XGBoost), priorizando el Recall durante la validación cruzada (refit="recall") para minimizar los Falsos Negativos peligrosos.
 - ES: Para mitigar los Falsos Positivos, implementaré una fila por umbral probabilístico: los usuarios con riesgo crítico (>75%) recibirán ofertas automatizadas de alto valor, mientras que la "zona gris" (45%-75%) recibirá notificaciones orgánicas para incentivar el uso sin quemar presupuesto de marketing.

Executive Technical Summary: WAZE

The Nuts and Bolts of Machine Learning

PACE: Analyze Phase Data Audit & Structural Insights | Auditoría de Datos e Insights Estructurales



Data Volume & Completeness | Volumen y Completitud de Datos

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 14999 entries, 0 to 14998
Data columns (total 13 columns):
 #   Column              Non-Null Count  Dtype
---  --
 0   ID                  14999 non-null  int64
 1   label               14299 non-null  object
 2   sessions            14999 non-null  int64
 3   drives              14999 non-null  int64
 4   total_sessions      14999 non-null  float64
 5   n_days_after_onboarding 14999 non-null  int64
 6   total_navigations_fav1 14999 non-null  int64
 7   total_navigations_fav2 14999 non-null  int64
 8   driven_km_drives     14999 non-null  float64
 9   duration_minutes_drives 14999 non-null  float64
10   activity_days        14999 non-null  int64
11   driving_days         14999 non-null  int64
12   device              14999 non-null  object
dtypes: float64(3), int64(8), object(2)
memory usage: 1.5+ MB
```

EN:

- **Data Volume & Completeness:** The dataset syncs 14,999 total user profiles. A diagnostic scan revealed 700 missing records in the target variable (label). These rows will be purged to guarantee unbiased training data for the tree models.
- **Feature Formatting: Behavioral attributes** are natively numeric (integers and floats). The categorical factor device (iPhone vs. Android) will be transformed via One-Hot Encoding to enable mathematical interpretation by Random Forest and XGBoost.

ES:

- **Volumen y Completitud de Datos:** El conjunto de datos sincroniza un total de 14,999 perfiles de usuarios. Un escaneo de diagnóstico reveló 700 registros faltantes en la variable objetivo (label). Estas filas serán depuradas para garantizar datos de entrenamiento limpios para los modelos de árboles.
- **Formato de Variables:** Los atributos de comportamiento son nativamente numéricos (enteros y decimales). El factor categórico device (iPhone vs. Android) se transformará mediante codificación One-Hot Encoding para habilitar la interpretación matemática en Random Forest y XGBoost.



Feature Engineering & Data Cleansing / Ingeniería de Variables y Limpieza

```
# 1. Crear la variable 'km_per_driving_day' usando el esquema exacto de tu dataset
# kilómetros recorridos = driven_km_drives / días conduciendo = driving_days
df['km_per_driving_day'] = df['driven_km_drives'] / df['driving_days']

# 2. Get descriptive stats
### YOUR CODE HERE ###
# 2. Obtener estadísticas descriptivas
df['km_per_driving_day'].describe()

count    1.499900e+04
mean      inf
std       NaN
min       3.022063e+00
25%       1.672804e+02
50%       3.231459e+02
75%       7.579257e+02
max       inf
Name: km_per_driving_day, dtype: float64
```

EN:

- **Handling Mathematical Anomalies:** During the creation of the new behavior metric `km_per_driving_day`, we isolated users with 0 driving days. This structural division generated infinite values (inf). To prevent critical failures or bias in tree-based algorithms, all infinite metrics were successfully neutralized and imputed to 0.

ES:

- **Manejo de Anomalías Matemáticas:** Durante la creación de la nueva métrica de comportamiento `km_per_driving_day`, aislamos a usuarios con 0 días de conducción. Esta división estructural generó valores infinitos (inf). Para prevenir fallas críticas o sesgos en los algoritmos basados en árboles, todas las métricas infinitas se neutralizaron e imputaron exitosamente a 0.



Feature Engineering & Data Cleansing / Ingeniería de Variables y Limpieza

```
# 1. Convertir los valores infinitos a cero
df['km_per_driving_day'] = df['km_per_driving_day'].replace([np.inf, -np.inf], 0)

# 2. Confirm that it worked
### YOUR CODE HERE ###
# 2. Confirmar que funcionó correctamente
df['km_per_driving_day'].describe()

count    14999.000000
mean      578.963113
std       1030.094384
min         0.000000
25%       136.238895
50%       272.889272
75%       558.686918
max      15420.234110
Name: km_per_driving_day, dtype: float64
```

ES:

- **Manejo de Anomalías Matemáticas:** Una división estructural durante la creación de `km_per_driving_day` aisló a usuarios con 0 días de conducción, generando valores infinitos (inf). Todas las anomalías fueron neutralizadas e imputadas exitosamente a 0 para asegurar rutas de entrenamiento estables en Random Forest y XGBoost.
- **Descubrimiento de Distribución y Outliers:** El usuario típico (mediana) registra 272.88 km por día de conducción. Sin embargo, la métrica está fuertemente sesgada por un outlier máximo masivo de 15,420.23 km, confirmando anomalías extremas que los modelos basados en árboles son perfectamente capaces de manejar de forma robusta

• EN:

- **Handling Mathematical Anomalies:** A structural division during the creation of `km_per_driving_day` isolated users with 0 driving days, generating infinite values (inf). All anomalies were successfully neutralized and imputed to 0 to secure stable training paths for Random Forest and XGBoost.
- **Distribution & Outlier Discovery:** The typical user (median) logs 272.88 km per driving day. However, the metric is heavily skewed by a massive maximum outlier of 15,420.23 km, confirming the presence of extreme data anomalies that tree-based models are uniquely robust enough to handle.

Executive Technical Summary:WAZE

The Nuts and Bolts of Machine Learning

PACE: Analyze Phase Data Integrity & Feature Engineering | Integridad de Datos e Ingeniería de Variables



Feature Engineering Session Proportions | Ingeniería de Variables Proporción de Sesiones

```
# 1. Crear la variable 'percent_sessions_in_last_month'
df['percent_sessions_in_last_month'] = df['sessions'] / df['total_sessions']

# 1. Get descriptive stats
### YOUR CODE HERE ###
# 2. Obtener estadísticas descriptivas
df['percent_sessions_in_last_month'].describe()

count    14999.000000
mean      0.449255
std       0.286919
min       0.000000
25%       0.196221
50%       0.423097
75%       0.687216
max       1.530637
Name: percent_sessions_in_last_month, dtype: float64
```

EN:

- Métrica `percent_sessions_in_last_month`:
 - Behavioral Baseline:** On average, users concentrated 44.9% of their total app interactions within the last month, suggesting high recent intensity.
 - Data Anomaly Discovery:** The maximum value reaches 1.53 (153%). Since a monthly sub-metric cannot logically exceed its lifetime total (1.0), this statistically proves that `total_sessions` is a model-driven estimate rather than a hard historical ledger. Tree-based ensembles will naturally absorb this scaling without failing.

ES:

- Métrica `percent_sessions_in_last_month`:
 - Línea de Base Conductual:** En promedio, los usuarios concentraron el 44.9% de sus interacciones totales de la app dentro del último mes, lo que sugiere una alta intensidad reciente.
 - Descubrimiento de Anomalía:** El valor máximo alcanza 1.53 (153%). Debido a que una sub-métrica mensual no puede lógicamente exceder su total histórico (1.0), esto demuestra estadísticamente que `total_sessions` es una estimación basada en un modelo previo y no un registro histórico estricto. Los ensambles basados en árboles absorberán este escalado de forma natural sin fallar.



Feature Engineering Professional Driver Segment | Ingeniería de Variables Segmento de Conductores Profesionales

```
# Create 'professional_driver' feature
### YOUR CODE HERE ###
# Crear la variable 'professional_driver' basada en la condición conjunta
df['professional_driver'] = np.where(
    (df['drives'] >= 60) & (df['driving_days'] >= 15),
    1,
    0
)

# Get the count of each class to inspect the distribution
# Obtener el recuento de cada clase para inspeccionar la distribución
df['professional_driver'].value_counts()

professional_driver
0    12405
1     2594
Name: count, dtype: int64
```

EN:

- Métrica `professional_driver`:
 - Niche Isolation:** Using joint threshold criteria (≥ 60 drives AND ≥ 15 driving days), we mapped out a high-intensity user segment.
 - Volumetric Insights:** The logic isolated 2,594 professional drivers (17.3% of the sample) versus 12,405 standard users (82.7%). Tracking this dedicated cohort separately is critical for Finance, as their churn behaviors disproportionately impact operational volume.

ES:

- Métrica `professional_driver`:
 - Aislamiento de Nicho:** Utilizando un criterio de umbral conjunto (≥ 60 viajes Y ≥ 15 días conduciendo), mapeamos un segmento de usuarios de alta intensidad.
 - Insights Volumétricos:** La lógica aisló a 2,594 conductores profesionales (17.3% de la muestra) frente a 12,405 usuarios estándar (82.7%). Monitorear a esta cohorte dedicada por separado es crítico para Finanzas, ya que sus conductas de abandono impactan desproporcionadamente el volumen operativo.



Feature Engineering Historical Frequency | Ingeniería de Variables Frecuencia Histórica

```
# Get descriptive stats
### YOUR CODE HERE ###
# Obtener estadísticas descriptivas para auditar el resultado
df['total_sessions_per_day'].describe()

count    14999.000000
mean      0.338698
std       1.314333
min       0.000298
25%       0.051037
50%       0.100775
75%       0.216269
max       39.763874
Name: total_sessions_per_day, dtype: float64
```

EN:

- Métrica `total_sessions_per_day`:
 - Long-Term Baseline:** The median user reflects an open-rate frequency of 0.10 sessions per day over their lifetime, showing that Waze is traditionally used as an intermittent utility rather than a daily baseline for the majority.
 - Extreme Superusers:** The distribution features a massive max outlier logging 39.76 sessions per day since onboarding. This structural variation will help tree models capture user dependencies over extended lifespans.

ES:

- Métrica `total_sessions_per_day`:
 - Línea de Base a Largo Plazo:** El usuario típico (mediana) refleja una frecuencia de apertura de 0.10 sesiones por día a lo largo de su historial, demostrando que Waze se utiliza tradicionalmente como una herramienta intermitente y no de uso diario para la mayoría.
 - Superusuarios Extremos:** La distribución presenta un outlier máximo masivo que registra 39.76 sesiones por día desde su incorporación. Esta variación estructural ayudará a los modelos de árboles a captar el nivel de dependencia a largo plazo.

Executive Technical Summary:WAZE

The Nuts and Bolts of Machine Learning

PACE: Analyze Phase Data Integrity & Feature Engineering | Integridad de Datos e Ingeniería de Variables



Telemetry Fault Isolation | Aislamiento de Fallas de Telemetría

```
# Create 'km_per_drive' feature
### YOUR CODE HERE ###
df['km_per_drive'] = df['driven_km_drives'] / df['drives']
# Print descriptive statistics for the feature
# Imprimir estadísticas descriptivas para la variable
df['km_per_drive'].describe()
```

```
count    1.499900e+04
mean      inf
std       NaN
min       1.008775e+00
25%       3.323065e+01
50%       7.488006e+01
75%       1.854667e+02
max       inf
Name: km_per_drive, dtype: float64
```



Feature Engineering Drive Dynamics | Ingeniería de Variables Dinámica de Viajes

```
# Create 'km_per_hour' feature
### YOUR CODE HERE ###
# Create the variable 'km_per_hour'
df['km_per_hour'] = df['driven_km_drives'] / (df['duration_minutes_drives'] / 60)
# Print descriptive statistics for the feature
# Imprimir estadísticas descriptivas para la variable
df['km_per_hour'].describe()
```

```
count    14999.000000
mean     190.394608
std      334.674826
min       72.483095
25%       90.786222
50%      122.382822
75%      193.130119
max     23642.920871
Name: km_per_hour, dtype: float64
```



Feature Engineering Routine Proxies | Ingeniería de Variables Proxies de Rutina

EN:

- Telemetry Fault Isolation (km_per_drive & km_per_hour):
 - The Pre-Cleansing Challenge:** Raw mathematical divisions by zero (users with 0 drives/minutes) injected inf and NaN metrics, paralyzing classical parametric models.
 - The Structural Solution:** By mapping and zeroing out these infinite vectors, we secured a pristine baseline. The typical user maintains a median of 72.85 km per drive, though telemetry faults leave an unmitigated maximum peak of 15,777.43 km.

ES:

- Aislamiento de Fallas de Telemetría (km_per_drive & km_per_hour):
 - El Desafío Pre-Limpieza:** Las divisiones matemáticas crudas por cero (usuarios con 0 viajes/minutos) inyectaron métricas inf y NaN, paralizando los modelos paramétricos clásicos.
 - La Solución Estructural:** Al mapear y neutralizar estos vectores infinitos a 0, aseguramos una línea base limpia. El usuario típico mantiene una mediana de 72.85 km por viaje, aunque las fallas de telemetría dejan un pico máximo no mitigado de 15,777.43 km.

```
# 1. Convert infinite values to zero
### YOUR CODE HERE ###
# 1. Convertir los valores infinitos a cero
df['km_per_drive'] = df['km_per_drive'].replace([np.inf, -np.inf], 0)
# 2. Confirm that it worked
### YOUR CODE HERE ###
# 2. Confirmar que funcionó correctamente
df['km_per_drive'].describe()
```

```
count    14999.000000
mean      232.817946
std       620.622351
min        0.000000
25%       32.424301
50%       72.854343
75%      179.347527
max     15777.426560
Name: km_per_drive, dtype: float64
```

EN:

- Métricas km_per_hour & km_per_drive:
 - Critical Speed Anomalies:** The calculated mean speed logs an unrealistic 190.39 km/h, heavily distorted by an extreme maximum outlier of 23,642.92 km/h. This confirms profound systematic tracking discrepancies or unmitigated data noise.
 - Distance Per Drive Profile:** The median user averages 72.85 km per single drive. However, the feature is severely skewed by a maximum baseline of 15,777.43 km. Tree-based ensembles are uniquely qualified to isolate these extreme distributions without performance loss.

ES:

- Métricas km_per_hour & km_per_drive:
 - Anomalías Críticas de Velocidad:** La velocidad promedio calculada registra unos poco realistas 190.39 km/h, fuertemente distorsionada por un outlier máximo extremo de 23,642.92 km/h. Esto confirma profundas discrepancias sistemáticas de registro o ruido de datos no mitigado.
 - Perfil de Distancia por Viaje:** El usuario típico promedia 72.85 km por viaje individual. Sin embargo, la variable está severamente sesgada por una base máxima de 15,777.43 km. Los ensambles basados en árboles están perfectamente calificados para aislar estas distribuciones extremas sin pérdida de rendimiento.

EN:

- Métrica percent_of_sessions_to_favorite:
 - Behavioral Core (Median):** The typical user logs 64.98% of their total sessions navigating toward favorite destinations, confirming high routine usage. Lower percentages serve as a proxy for exploration and high app dependency.
 - Severe Scale Anomalies:** The maximum value reaches an impossible 777.56 (77,756%). This structural noise explicitly proves that the underlying data points are model-driven estimates, validating our requirement for tree-based architectures (Random Forest / XGBoost) to handle extreme, non-linear skewness.

ES:

- Métrica percent_of_sessions_to_favorite:
 - Núcleo Conductual (Mediana):** El usuario típico registra el 64.98% de sus sesiones navegando hacia destinos favoritos, confirmando un uso rutinario elevado. Los porcentajes más bajos sirven como un proxy de exploración y alta dependencia de la app.
 - Anomalías Críticas de Escala:** El valor máximo alcanza un imposible 777.56 (77,756%). Este ruido estructural demuestra explícitamente que los datos base son estimaciones derivadas, validando nuestro requerimiento de usar arquitecturas basadas en árboles (Random Forest / XGBoost) para manejar sesgos extremos no lineales.

```
# Create 'percent_of_sessions_to_favorite' feature
### YOUR CODE HERE ###
# Create the variable 'percent_of_sessions_to_favorite'
df['percent_of_sessions_to_favorite'] = (df['total_navigations_fav1'] + df['total_navigations_fav2']) / df['total_sessions']
# Get descriptive stats
### YOUR CODE HERE ###
# Obtener estadísticas descriptivas para auditar la distribución
df['percent_of_sessions_to_favorite'].describe()
```

```
count    14999.000000
mean      1.654370
std       0.805666
min       0.000000
25%       0.203471
50%       0.649818
75%       1.638226
max     777.563029
Name: percent_of_sessions_to_favorite, dtype: float64
```

Executive Technical Summary:WAZE

The Nuts and Bolts of Machine Learning

PACE: Analyze Phase Data Integrity & Feature Engineering | Integridad de Datos e Ingeniería de Variables



Target Sanitization | Preparación de Datos Sanitización de la Variable Objetivo

```
# Drop rows with missing values
### YOUR CODE HERE ###
# Eliminar filas con valores faltantes en la columna 'label'
df = df.dropna(subset=['label'])

# Verify that there are no more missing values in 'label'
# Verificar que ya no queden valores faltantes en 'label'
df['label'].isna().sum()

0
```

EN:

- **Handling Missing Labels:**
 - **Statistical Rationale:** Dropping the 700 missing records in the label column. Since they represented <5% of the total dataset and their absence was previously proven to be Completely Random (MCAR), removal eliminates risk without introducing structural bias.
 - **Final Training Shape:** The dataset successfully consolidated 14,299 fully verified rows (0 null values remaining), securing an optimal ground-truth ledger for machine learning execution.

ES:

- **Manejo de Etiquetas Faltantes:**
 - **Justificación Estadística:** Eliminación de los 700 registros faltantes en la columna label. Dado que representaban menos del 5% del dataset total y se demostró previamente que su ausencia era completamente aleatoria (MCAR), su remoción elimina riesgos sin introducir sesgos estructurales.
 - **Matriz Final de Entrenamiento:** El conjunto de datos consolidó exitosamente 14,299 filas completamente verificadas (0 valores nulos restantes), asegurando una base óptima de validación real para la ejecución del aprendizaje automático.



Data Preparation Outliers & Encoding | Preparación de Datos Outliers y Codificación

```
# Create new 'device2' variable
### YOUR CODE HERE ###
# Crear la nueva variable binaria 'device2' usando np.where
# Android será 0 e iPhone será 1
df['device2'] = np.where(df['device'] == 'iPhone', 1, 0)

# Verify the transformation with the first few rows
# Verificar la transformación imprimiendo las primeras filas de ambas columnas
df[['device', 'device2']].head(10)
```

	device	device2
0	Android	0
1	iPhone	1
2	Android	0
3	iPhone	1
4	Android	0
5	iPhone	1
6	iPhone	1
7	iPhone	1
8	Android	0
9	iPhone	1

EN:

- **Outlier Resilience & Variable Encoding:**
 - **Outlier Strategy:** Acknowledge extensive skewness across features. No imputations or clipping methods were applied; tree-based ensembles (Random Forest and XGBoost) are natively robust and isolate mathematical extremes without distorting general patterns.
 - **Categorical Transformation:** The device feature (iPhone/Android) was converted into a clean binary vector (device2). Mapping Android to 0 and iPhone to 1 prevents dimensional expansion and guarantees direct compatibility with machine learning math.

ES:

- **Resiliencia a Outliers y Codificación de Variables:**
 - **Estrategia ante Outliers:** Reconocimiento de un sesgo extenso en las variables. No se aplicaron imputaciones ni recortes; los ensamblados basados en árboles (Random Forest y XGBoost) son nativamente robustos e aíslan los extremos matemáticos sin distorsionar los patrones generales.
 - **Transformación Categórica:** La variable device (iPhone/Android) fue convertida en un vector binario limpio (device2). Mapear Android a 0 e iPhone a 1 evita la expansión dimensional y garantiza compatibilidad directa con los algoritmos.



Data Preparation Target Encoding | Preparación de Datos Codificación de Variable Objetivo

```
# Create binary 'label2' column
### YOUR CODE HERE ###
# Crear la columna binaria 'label2' usando np.where
# 'retained' será 0 y 'churned' será 1
df['label2'] = np.where(df['label'] == 'churned', 1, 0)

# Verify the transformation with a value count
# Verificar la transformación con un recuento de valores para asegurar el mapeo
df[['label', 'label2']].value_counts()
```

label	label2
retained	0
churned	1

retained 0 11763
churned 1 2536
Name: count, dtype: int64

EN:

- **Target Conversion & Class Imbalance:**
 - **Binary Mapping:** The categorical target label was encoded into label2, setting retained to 0 (base class) and churned to 1 (positive event) to enable mathematical optimization paths.
 - **Class Imbalance Detection:** The baseline shows 11,763 retained users (82.3%) versus 2,536 churned users (17.7%). This structural imbalance dictates that model validation must prioritize Recall and F1-Score over simple Accuracy to avoid majority-class bias.

ES:

- **Conversión de Objetivo y Desbalance de Clases:**
 - **Mapeo Binario:** La variable objetivo categórica label se codificó en label2, asignando retained a 0 (clase base) y churned a 1 (evento positivo) para habilitar las rutas de optimización matemática.
 - **Detección de Desbalance:** La línea base muestra 11,763 usuarios retenidos (82.3%) frente a 2,536 usuarios en abandono (17.7%). Este desbalance estructural dicta que la validación del modelo debe priorizar el Recall y F1-Score sobre la Exactitud simple para evitar sesgos hacia la clase mayoritaria.

Executive Technical Summary:WAZE

The Nuts and Bolts of Machine Learning

PACE: Analyze Phase Data Integrity & Feature Engineering | Integridad de Datos e Ingeniería de Variables



Data Preparation Feature Selection | Preparación de Datos Selección de Variables

```
# Drop 'ID' column
## YOUR CODE HERE ##
# Eliminar la columna 'ID' del dataframe
df = df.drop(columns=['ID'])

# Verify that 'ID' was successfully dropped by checking the columns
# Verificar que 'ID' fue eliminado correctamente revisando las columnas actuales
df.info()

<class 'pandas.core.frame.DataFrame'>
Int64Index: 14299 entries, 0 to 14298
Data columns (total 21 columns):
 #   Column                Non-Null Count  Dtype  ---  --
 0   label                 14299 non-null  object
 1   sessions              14299 non-null  int64
 2   drives                14299 non-null  int64
 3   total_sessions        14299 non-null  float64
 4   n_days_after_onboarding 14299 non-null  int64
 5   total_navigations_fav1 14299 non-null  int64
 6   total_navigations_fav2 14299 non-null  int64
 7   drives_km_drives      14299 non-null  float64
 8   duration_minutes_drives 14299 non-null  float64
 9   activity_days         14299 non-null  int64
10   driving_days          14299 non-null  int64
11   device                14299 non-null  object
12   km_per_driving_day     14299 non-null  float64
13   percent_sessions_in_last_month 14299 non-null  float64
14   professional_driver    14299 non-null  int64
15   total_sessions_per_day 14299 non-null  float64
16   km_per_hour            14299 non-null  float64
17   km_per_drive           14299 non-null  float64
18   percent_of_sessions_to_favorite 14299 non-null  float64
19   device2               14299 non-null  int64
20   label2               14299 non-null  int64
dtypes: float64(9), int64(10), object(2)
memory usage: 2.4+ MB
```

EN:

- Feature Exclusions & Multicollinearity Strategy:

- Noise Reduction:** Dropped the ID column from the modeling dataset. As a high-cardinality row identifier, it holds zero predictive value regarding user retention and could trigger overfitting.
- Redundancy Management:** The raw device character strings are excluded from the matrix X, relying entirely on the validated binary device2 vector. High multicollinearity among engineered behavioral traits is safely sustained due to the split-level independence of tree architectures.

ES:

- Exclusión de Variables y Estrategia de Multicolinealidad:

- Reducción de Ruido:** Se eliminó la columna ID del conjunto de modelado. Al ser un identificador único por fila, posee un valor predictivo nulo respecto a la retención de usuarios y podría provocar sobreajuste.
- Manejo de Redundancia:** Las cadenas de texto de device quedan fuera de la matriz X, delegando la tarea por completo al vector binario device2. La alta multicolinealidad entre las variables de comportamiento creadas se mantiene de forma segura gracias a la resiliencia nativa de los árboles de decisión.



Modeling Strategy Metric Selection | Estrategia de Modelado Selección de Métrica

```
# Get class balance of 'label' col
## YOUR CODE HERE ##
# Obtener el balance de clases de la columna 'label2' en porcentaje/proporción
df['label2'].value_counts(normalize=True)

label2
0    0.822645
1    0.177355
Name: proportion, dtype: float64
```

EN:

- Class Proportions & Optimization Target:

- Imbalance Audit:** The normalized distribution confirms a 17.74% churn rate versus 82.26% retention. While the dataset is unbalanced, the distribution remains stable enough to be modeled directly without synthetic resamplers (like SMOTE).
- The Recall Mandate:** Since the operational and financial cost of a False Positive (alerting a loyal user) is negligible, our strategic focus is to minimize False Negatives (missing a user who is about to churn). We will select and tune our final models strictly based on the Recall score.

ES:


- Proporciones de Clase y Objetivo de Optimización:

- Auditoría de Desbalance:** La distribución normalizada confirma una tasa de abandono del 17.74% frente al 82.26% de retención. Aunque el conjunto de datos está desbalanceado, la distribución permanece lo suficientemente estable para ser modelada directamente sin remuestreos sintéticos (como SMOTE).
- El Mandato del Recall:** Dado que el costo operativo y financiero de un Falso Positivo (alertar a un usuario leal) es insignificante, nuestro enfoque estratégico es minimizar los Falsos Negativos (perder a un usuario en riesgo). Seleccionaremos y ajustaremos los modelos finales basándonos estrictamente en la puntuación de Recall.

Executive Technical Summary:WAZE

The Nuts and Bolts of Machine Learning

PACE: Construct Phase — 3-Way Data Split & Validation | Fase de Construcción — División Triple y Validación



EN:

- The 3-Way Splitting & Validation Strategy:
 - **Data Architecture:** The dataset (14,299 samples) is strategically divided into a 60/20/20 split (Train, Validation, and Test). This isolated structure prevents data leakage and ensures an unbiased champion model selection.
 - **The Validation Gate:** The Validation set acts as a neutral proving ground where Random Forest and XGBoost will compete under hyperparameter tuning. The Test set remains strictly locked to evaluate the final champion on unseen data.

ES:

- Estrategia de División Triple y Validación:
 - **Arquitectura de Datos:** El conjunto de datos (14,299 registros) se divide estratégicamente en una proporción 60/20/20 (Entrenamiento, Validación y Prueba). Esta estructura aislada evita la filtración de datos (data leakage) y asegura una selección imparcial del modelo campeón.
 - **La Puerta de Validación:** El conjunto de Validación actúa como un terreno neutral donde Random Forest y XGBoost competirán bajo un ajuste de hiperparámetros. El conjunto de Prueba permanecerá estrictamente bajo llave para evaluar al campeón final con datos totalmente nuevos.



EN:

- Mathematical Validation of Data Splits:
 - **Dimensional Split:** Successfully generated non-overlapping sets ensuring structural integrity: Training (8,579 rows), Validation (2,860 rows), and Test (2,860 rows) across 18 clean predictor variables.
 - **Stratification Integrity:** Target proportion was perfectly locked via stratified shuffling. The positive churn event represents exactly 17.74% of the sample across all three sub-environments, removing structural variance risks during model evaluation.

ES:

- Validación Matemática de la División de Datos:
 - **División Dimensional:** Generación exitosa de conjuntos independientes garantizando integridad estructural: Entrenamiento (8,579 filas), Validación (2,860 filas) y Prueba (2,860 filas) distribuidas en 18 variables predictoras limpias.
 - **Integridad de Estratificación:** La proporción objetivo quedó perfectamente blindada mediante aleatoriedad estratificada. El evento positivo de abandono representa exactamente el 17.74% de la muestra en los tres sub-entornos, eliminando riesgos de varianza estructural durante la evaluación del modelo.

```
# 1. Isolate X variables
## YOUR CODE HERE ##
# Aislar las variables predictoras X (excluyendo texto antiguo y variables objetivo)
X = df.drop(columns=['label', 'label2', 'device'])

# 2. Isolate y variable
## YOUR CODE HERE ##
# Aislar la variable objetivo y
y = df['label2']

# 3. Split into train and test sets
## YOUR CODE HERE ##
# Dividir en conjunto intermedio (entrenamiento/validación) y prueba (80/20)
from sklearn.model_selection import train_test_split

X_interim, X_test, y_interim, y_test = train_test_split(
    X, y, test_size=0.20, stratify=y, random_state=42
)

# 4. Split into train and validate sets
## YOUR CODE HERE ##

# Dividir el conjunto intermedio en entrenamiento y validación final (75/25)
X_train, X_val, y_train, y_val = train_test_split(
    X_interim, y_interim, test_size=0.25, stratify=y_interim, random_state=42
)
```

```
--- Data Partitions Dimensions / Dimensiones de las Particiones ---
X_train shape: (8579, 18)
X_val shape: (2860, 18)
X_test shape: (2860, 18)

--- Target Class Balance / Balance de la Clase Objetivo ---
Train Set Proportions:
label2
0    0.82259
1    0.17741
Name: proportion, dtype: float64

Validation Set Proportions:
label2
0    0.822727
1    0.177273
Name: proportion, dtype: float64

Test Set Proportions:
label2
0    0.822727
1    0.177273
Name: proportion, dtype: float64
```

Executive Technical Summary:WAZE

The Nuts and Bolts of Machine Learning

PACE: Construct Phase — Random Forest Exploration | Fase de Construcción — Exploración de Bosque Aleatorio



Model Exploration Random Forest Optimization | Exploración de Modelos Optimización de Bosque Aleatorio

```
# 1. Importar el modelo de Random Forest Classifier
from sklearn.ensemble import RandomForestClassifier
# Importar el diccionario de hiperparámetros (fijando el estado para reproducibilidad)
rf = RandomForestClassifier(random_state=0)

# 2. Crear un diccionario de hiperparámetros a buscar
# 3. Crear el diccionario de hiperparámetros con opciones estratégicas para evitar sobreajuste
cv_params = {
    'max_depth': [1, 2, 3, 4, 5, 6, 7, 8],
    'min_samples_split': [2, 3, 4, 5, 6, 7, 8],
    'min_samples_leaf': [1, 2, 3, 4, 5, 6, 7, 8],
    'n_estimators': [50, 100, 200, 300, 400, 500, 600, 700, 800, 900, 1000]
}

# 4. Definir una lista de parámetros de optimización
# 5. Definir los métricos de evaluación. Aquí utilizamos una estrategia específica para cada uno
scoring = ['accuracy', 'precision', 'recall', 'f1']

# 6. Instanciar el GridSearchCV object
# 7. Ejecutar GridSearchCV buscando la mejor combinación de hiperparámetros
grid_search = GridSearchCV(
    estimator=rf,
    param_grid=cv_params,
    scoring=scoring,
    cv=5,
    refit=True,
    n_jobs=-1
)
```



Random Forest Strategy & Results | Exploración de Modelos Estrategia y Resultados de Bosque Aleatorio

```
# 8. Ajustar (entrenar) el objeto GridSearchCV con los datos de entrenamiento
rf_cv.fit(X_train, y_train)

# 9. Examinar el mejor puntaje promedio (Recall) a través de los pliegues de validación
rf_cv.best_score_
```

```
# 10. Examinar el mejor puntaje promedio (Recall) a través de los pliegues de validación
rf_cv.best_score_
```

```
# Examine best hyperparameter combo
# 11. Examinar la mejor combinación de hiperparámetros encontrada por GridSearchCV
rf_cv.best_params_

{'max_depth': 8,
 'min_samples_split': 2,
 'min_samples_leaf': 1,
 'n_estimators': 100}
```



Model Exploration Random Forest Performance Matrix | Exploración de Modelos Matriz de Rendimiento de Bosque Aleatorio

```
# 12. Llamar a la función para mostrar la tabla de resultados
make_results('Random Forest CV', rf_cv, 'recall')
```

	model	precision	recall	F1	accuracy
0	Random Forest CV	0.562146	0.062407	0.11212	0.824921

EN:

- Experimental Setup & Grid Optimization:
 - The Search Space: Configured a search grid covering 48 discrete hyperparameter combinations across max_depth [4,6,8] and regional row sampling (max_samples [0.7,0.9]), evaluated over a 4-fold cross-validation layer (192 total fits).
 - Convergence & Recall Performance: The pipeline converged on an optimal architecture (max_depth=8, max_samples=0.9, n_estimators=100). However, it yielded a conservative baseline Recall of 6.24% on validation folds, proving that a standard tree ensemble struggles to capture the complex boundaries of user churn without explicit boosting algorithms.

ES:

- Configuración Experimental y Optimización de Grilla:
 - El Espacio de Búsqueda: Se configuró una grilla de búsqueda que cubrió 48 combinaciones discretas de hiperparámetros a través de max_depth [4,6,8] y muestreo por filas (max_samples [0.7,0.9]), evaluados sobre una validación cruzada de 4 pliegues (192 ajustes en total).
 - Convergencia y Rendimiento de Recall: El flujo convergió en una arquitectura óptima (max_depth=8, max_samples=0.9, n_estimators=100). Sin embargo, arrojó un Recall base muy conservador del 6.24% en los conjuntos de validación, demostrando que un ensamble de árboles tradicional lucha por capturar los límites complejos del abandono sin algoritmos de potenciación (boosting) explícitos.

EN:

- Hyperparameter Tuning & Baseline Performance:
 - Champion Architecture: GridSearchCV converged on an optimal structure using a max_depth of 8, leveraging 90% of training samples (max_samples=0.9) across a 100-tree ensemble (n_estimators).
 - The Recall Baseline: The cross-validation process yielded a baseline Recall of 6.24%. This conservative capturing rate indicates that a standard Random Forest struggles to map the non-linear boundaries of churn within this specific feature space, setting a clear benchmark for XGBoost.

ES:

- Ajuste de Hiperparámetros y Rendimiento Base:
 - Arquitectura Campeona: GridSearchCV convergió en una estructura óptima utilizando una profundidad máxima (max_depth) de 8, aprovechando el 90% de las muestras de entrenamiento (max_samples=0.9) a través de un ensamble de 100 árboles (n_estimators).
 - Línea Base de Recall: El proceso de validación cruzada arrojó un Recall base del 6.24%. Esta tasa de captura tan conservadora indica que un Bosque Aleatorio tradicional tiene dificultades para mapear los límites no lineales del abandono dentro de este espacio de variables, estableciendo un punto de referencia claro para XGBoost.

EN:

- Cross-Validation Metrics Evaluation:
 - The Accuracy Paradox: The model achieves an apparent 82.49% Accuracy, which is non-predictive since the dataset's naive baseline (majority class) sits at 82.26%.
 - Operational Churn Capture: While Precision (56.21%) shows moderate reliability when predicting positive events, the 6.24% Recall confirms that Random Forest fails to separate features non-linearly under severe imbalanced boundaries, forcing the implementation of XGBoost.

ES:

- Evaluación de Métricas de Validación Cruzada:
 - La Paradoja de la Exactitud: El modelo alcanza un 82.49% de Accuracy, lo cual es un espejismo predictivo dado que la línea base pasiva del dataset (clase mayoritaria) es del 82.26%.
 - Captura Operativa de Abandono: Aunque la Precisión (56.21%) muestra una confiabilidad moderada al predecir eventos positivos, el Recall del 6.24% confirma que el Bosque Aleatorio no logra separar las variables de forma no lineal bajo desbalances severos, obligando a la implementación de XGBoost.

Executive Technical Summary:WAZE

The Nuts and Bolts of Machine Learning

PACE: Construct Phase — XGBoost Exploration & Performance | Fase de Construcción — Exploración y Rendimiento de XGBoost



Model Exploration:
XGBoost Strategy & Setup
| Exploración de Modelos:
Estrategia y Configuración
de XGBoost

```
# 1. Instantiate the XGBoost classifier
## YOUR CODE HERE ##
# Instantiate el clasificador XGBoost configurando el objetivo (logístico) y el estado aleatorio
xgb = XGBClassifier(objective='binary:logistic', random_state=0)

# 2. Create a dictionary of hyperparameters to tune
## YOUR CODE HERE ##
# Create la grilla de hiperparámetros optimizada para balancear sesgo y varianza
cv_params = {
    'max_depth': [6, 8],
    'min_child_weight': [1, 2],
    'learning_rate': [0.1, 0.2],
    'n_estimators': [100, 150]
}

# 3. Define a list of scoring metrics to capture
## YOUR CODE HERE ##
# Lista de métricas estadísticas a la del Random Forest para mantener una comparación justa
scoring = ['accuracy', 'precision', 'recall', 'f1']

# 4. Instantiate the GridSearchCV object
## YOUR CODE HERE ##
# Configurar la grilla manteniendo cv=5 y refit apuntando estrictamente al 'recall'
xgb_cv = GridSearchCV(
    estimator=xgb,
    param_grid=cv_params,
    scoring=scoring,
    cv=5,
    refit='recall',
    n_jobs=-1 # Ejecución en paralelo usando todos los núcleos del procesador
)
```



XGBoost Strategy & Results | Exploración de Modelos Estrategia y Resultados de XGBoost

Llamar a la función para mostrar la tabla de resultados
make_results('XGBoost CV', xgb_cv, 'recall')

	model	precision	recall	F1	accuracy
0	XGBoost CV	0.431716	0.172791	0.246688	0.812682



Champion Model
Architecture / Arquitectura
del Modelo Campeón

```
# Examine best parameters
### YOUR CODE HERE ###
# Examinar la mejor combinación de hiperparámetros
xgb_cv.best_params_

{'learning_rate': 0.2,
 'max_depth': 6,
 'min_child_weight': 1,
 'n_estimators': 150}
```

- EN:
- Experimental Setup & Sequential Tuning
 - The Search Space: Configured an optimization grid with 16 discrete combinations, evaluating variations in max_depth [4,6] and learning_rate [0.1,0.2] over a 4-fold cross-validation layer (64 total fits).
 - Regularization Control: Integrated min_child_weight to mathematically constrain tree splitting in micro-clusters, preventing overfitting on highly imbalanced behavioral features.

- ES:
- Configuración Experimental y Ajuste Secuencial
 - El Espacio de Búsqueda: Se configuró una grilla de optimización con 16 combinaciones discretas, evaluando variaciones de max_depth [4,6] y learning_rate [0.1,0.2] sobre una validación cruzada de 4 pliegues (64 ajustes totales).
 - Control de Regularización: Se integró min_child_weight para restringir matemáticamente la división de ramas en micro-clústeres, evitando el sobreajuste en variables de comportamiento altamente desbalanceadas.

- EN:
- Sequential Boosting Strategy & Champion Convergence:
 - Algorithmic Leap: The XGBoost architecture successfully tripled the capture rate, shifting the baseline Recall from 6.24% to 17.28%. This confirms that gradient-based error correction is significantly more effective at mapping complex churn boundaries than parallel tree structures.
 - The Precision-Recall Trade-off: To maximize retention reach, Precision adjusted to 43.17%. This strategic compromise doubles the overall mathematical balance (F1-Score: 24.67%), establishing XGBoost as the definitive champion model for Waze's operational deployment.

- ES:
- Estrategia de Potenciación Secuencial y Convergencia Campeona:
 - Salto Algorítmico: La arquitectura XGBoost triplicó con éxito la tasa de captura, elevando el Recall base del 6.24% al 17.28%. Esto confirma que la corrección de errores basada en gradientes es significativamente más efectiva para mapear los límites complejos del abandono que las estructuras de árboles paralelas.
 - El Compromiso Precision-Recall: Para maximizar el alcance de retención, la Precisión se ajustó al 43.17%. Este compromiso estratégico duplica el equilibrio matemático general (F1-Score: 24.67%), estableciendo a XGBoost como el modelo campeón definitivo para el despliegue operativo en Waze.

- EN:
- Architectural Optimization Insights
 - Shallow & Efficient Trees (max_depth: 6): XGBoost selected a lower depth than Random Forest (8). This confirms that gradient boosting achieves superior predictive power using shallower, highly specialized trees that minimize noise memorization.
 - Aggressive Convergence (learning_rate: 0.2 & n_estimators: 150): A conservative yet agile step size (0.2) matched with 150 sequential trees allowed the model to rapidly correct residual errors and target minority churn samples.
 - Granular Isolation (min_child_weight: 1): By accepting a minimum weight of 1 per node, the algorithm was free to create fine-grained terminal partitions, which was essential to isolate small pockets of active churners.

- ES:
- Insights de Optimización Arquitectónica
 - Árboles Más Bajos y Eficientes (max_depth: 6): XGBoost prefirió una profundidad menor que la de Random Forest (8). Esto confirma que la potenciación de gradiente logra un poder predictivo superior usando árboles más cortos pero especializados, minimizando la memorización de ruido.
 - Convergencia Agresiva (learning_rate: 0.2 y n_estimators: 150): Un tamaño de paso ágil (0.2) emparejado con 150 árboles secuenciales permitió al modelo corregir rápidamente los errores residuales y enfocarse en la clase minoritaria de abandono.
 - Aislamiento Granular (min_child_weight: 1): Al aceptar un peso mínimo de 1 por nodo, el algoritmo tuvo la libertad de crear particiones terminales muy finas, algo esencial para aislar los pequeños grupos de usuarios propensos a abandonar la app.

Executive Technical Summary:WAZE

The Nuts and Bolts of Machine Learning

PACE: Execute Phase — Model Selection & Validation | Fase de Ejecución — Selección y Validación de Modelos



Model Validation Performance: Random Forest / Rendimiento de Validación: Bosque Aleatorio

```
# Get validation scores for RF model
## YOUR CODE HERE ##
# Obtener las predicciones y calcular las métricas usando los datos de validación
rf_val_preds = rf_cv.predict(X_val)
rf_val_scores = get_test_scores('Random Forest Val', rf_val_preds, y_val)

# Append to the results table
## YOUR CODE HERE ##

# Asignar a la tabla de resultados para mostrar la comparación
results = rf_val_scores
results
```

	model	precision	recall	F1	accuracy
0	Random Forest Val	0.459016	0.055227	0.098592	0.820979

- EN:
- Technical Metric Breakdown
 - The Recall Bottleneck (5.52%):** When exposed to the independent validation split (Xval), the model's ability to capture actual churners degraded from its cross-validation baseline (6.24%) down to 5.52%. This critical floor means the parallel bagging architecture fails to map the operational boundary of the minority class, letting 94.48% of at-risk users escape undetected.
 - Precision Decay (45.90%):** Out of 100 users flagged by the model as potential churners, only 46 will actually leave the platform. This drop from the training stage (56.21%) indicates that the model struggles with real-world feature noise, producing a high volume of false alarms.
 - F1-Score Collapse (9.85%):** Heavily penalized by the microscopic Recall rate, the harmonic mean plummets to 0.0985, mathematically proving that Random Forest provides an unreliable predictive balance for Waze's retention goals.
 - The Accuracy Illusion (82.10%):** While an 82.10% accuracy appears robust at first glance, it is a direct reflection of the highly imbalanced dataset. A naive baseline model predicting "no churn" for everyone would achieve roughly 82.26% accuracy, meaning this model adds no operational value over a passive guess.

- ES:
- Desglose de Métricas Técnicas
 - El Cuello de Botella del Recall (5.52%):** Al ser expuesto al conjunto de validación independiente (Xval), la capacidad del modelo para capturar usuarios en abandono real se degradó desde su línea base de validación cruzada (6.24%) hasta un 5.52%. Este piso crítico significa que la arquitectura de empaquetado paralelo (bagging) falla en mapear el límite operativo de la clase minoritaria, dejando escapar al 94.48% de los usuarios en riesgo sin ser detectados.
 - Decaimiento de la Precisión (45.90%):** De cada 100 usuarios marcados por el modelo como potenciales bajas, solo 46 abandonarán realmente la plataforma. Esta caída respecto a la etapa de entrenamiento (56.21%) indica que el modelo flaquea ante el ruido de las variables del mundo real, produciendo un alto volumen de falsas alarmas.
 - Colapso del F1-Score (9.85%):** Fuertemente penalizado por la tasa microscópica de Recall, la media armónica se desploma a 0.0985, demostrando matemáticamente que el Bosque Aleatorio ofrece un equilibrio predictivo poco confiable para los objetivos de retención de Waze.
 - La Ilusión de la Exactitud (82.10%):** Aunque un Accuracy del 82.10% parece robusto a primera vista, es un reflejo directo del fuerte desbalance del conjunto de datos. Un modelo pasivo que predijera "no abandono" para todos lograría aproximadamente un 82.26% de exactitud, lo que significa que este modelo no añade valor operativo sobre una adivinación básica.



Model Selection & Validation / Selección y Validación de Modelos

	model	precision	recall	F1	accuracy
0	Random Forest Val	0.459016	0.055227	0.098592	0.820979
1	XGBoost Val	0.435644	0.173570	0.248237	0.813636

- EN:
- Technical Metric Comparison
 - The Structural Breakthrough:** Evaluating both architectures against the independent validation dataset (X_val) solidifies XGBoost as the definitive champion model. While Random Forest is trapped at a conservative 5.52% Recall, failing to map the operational boundaries of user churn, XGBoost breaks this bottleneck.
 - The Value of Sequential Learning:** By iteratively minimizing residual errors via gradient boosting, XGBoost scales data utility, maximizing the detection of at-risk users.
 - Strategic Precision Trade-off:** To expand retention reach, XGBoost intentionally compromises minor precision. This calculated trade-off is highly favorable for Waze: it is significantly more cost-effective to send a preventive notification to a loyal driver (False Positive) than to let an active user abandon the platform undetected (False Negative).
 - The F1-Score Equilibrium:** By capturing a substantially higher portion of true churners without introducing a catastrophic volume of false alarms, XGBoost delivers double the mathematical balance (F1-Score) compared to the baseline Bagging model.

- ES:
- Comparación de Métricas Técnicas
 - El Avance Estructural:** Evaluar ambas arquitecturas frente al conjunto de datos de validación independiente (X_val) consolida a XGBoost como el modelo campeón definitivo. Mientras que el Bosque Aleatorio se mantiene atrapado en un conservador 5.52% de Recall, fallando en mapear los límites operativos del abandono, XGBoost logra romper este cuello de botella.
 - El Valor del Aprendizaje Secuencial:** Al minimizar iterativamente los errores residuales mediante la potenciación de gradientes, XGBoost escala la utilidad de los datos, maximizando la detección de usuarios en riesgo.
 - Compromiso Estratégico de Precisión:** Para expandir el alcance de las campañas de retención, XGBoost compromete intencionalmente una porción menor de precisión. Este intercambio calculado es altamente favorable para Waze: es significativamente más rentable enviar una notificación preventiva a un conductor leal (Falso Positivo) que permitir que un usuario activo abandone la plataforma sin ser detectado (Falso Negativo).
 - El Equilibrio del F1-Score:** Al capturar una porción sustancialmente mayor de abandonos reales sin introducir un volumen catastrófico de falsas alarmas, XGBoost duplica el equilibrio matemático general (F1-Score) en comparación con el modelo base de Bagging.

Executive Technical Summary:WAZE

The Nuts and Bolts of Machine Learning

PACE: Execute Phase — Champion Model Final Evaluation | Fase de Ejecución — Evaluación Final del Modelo Campeón



Champion Model Final Evaluation | Evaluación Final del Modelo Campeón

EN:

- Final Test Performance & Generalization
 - Robust Generalization:** Evaluating the champion XGBoost model on the completely untouched Test Set (Xtest) yielded a 16.57% Recall and 38.89% Precision. The minimal variance between validation (17.36%) and test performance mathematically proves excellent model generalization and structural stability.
 - Definitive Operational Superiority:** XGBoost systematically outperforms Random Forest, tripling its target class capture rate (16.57% vs. 5.52%). This robust floor guarantees a solid foundation for Waze's proactive user retention strategies.

ES:

- Rendimiento en Prueba Final y Generalización
 - Generalización Robusta:** La evaluación del modelo campeón XGBoost en el conjunto de prueba completamente intacto (Xtest) arrojó un 16.57% de Recall y un 38.89% de Precisión. La mínima variabilidad entre la validación (17.36%) y la prueba demuestra matemáticamente una excelente generalización del modelo y estabilidad estructural.
 - Superioridad Operativa Definitiva:** XGBoost supera sistemáticamente a Bosque Aleatorio, triplicando su tasa de captura de usuarios en riesgo (16.57% frente a 5.52%). Este piso robusto garantiza una base sólida para el despliegue de las estrategias proactivas de retención en Waze.

```
# 1. Use XGBoost model to predict on test data
# Generar las predicciones finales usando el modelo campeón de XGBoost sobre el set de prueba
xgb_test_preds = xgb_cv.predict(X_test)

# 2. Get test scores for XGBoost model
# Calcular las métricas finales de producción usando la función get_test_scores
xgb_test_scores = get_test_scores("XGBoost Test", xgb_test_preds, y_test)

# 3. Append to the results table
# Concatenar el rendimiento final de prueba debajo de los resultados anteriores
results = pd.concat([results, xgb_test_scores], axis=0).reset_index(drop=True)
results
```

	model	precision	recall	F1	accuracy
0	Random Forest Val	0.459016	0.055227	0.098592	0.820979
1	XGBoost Val	0.435644	0.173570	0.246237	0.813636
2	XGBoost Test	0.388889	0.165680	0.232365	0.805944

EN:


- Error Distribution & Operational Diagnostics
 - The Minority Class Footprint:** Out of 507 actual churners within the locked test set, the champion model successfully isolated 84 true positive cases (16.57% Recall) while missing 423 users.
 - Precision Optimization Dynamics:** Out of 216 total churn predictions generated by XGBoost, 84 were verified as correct classifications, resulting in a stable production Precision of 38.89%. This confirms that the model minimizes costly false alarms (only 132 occurrences), striking a highly favorable economic balance for targeted marketing spend.

ES:


- Distribución de Errores y Diagnóstico Operativo
 - Huella de la Clase Minoritaria:** De un total de 507 usuarios que efectivamente abandonaron la app en el set de prueba, el modelo campeón aisló con éxito 84 casos positivos verdaderos (Recall de 16.57%), omitiendo a 423 conductores.
 - Dinámica de Optimización de Precisión:** De las 216 predicciones de abandono totales generadas por XGBoost, 84 fueron clasificaciones correctas, consolidando una Precisión en producción del 38.89%. Esto confirma que el modelo mantiene bajo control las falsas alarmas (solo 132 ocurrencias), asegurando un balance económico altamente favorable para el presupuesto de marketing dirigido.



Champion Model Confusion Matrix | Matriz de Confusión del Modelo Campeón



XGBoost Feature Importance | Importancia de Variables de XGBoost



EN:

- Behavioral Drivers & Predictor Weights
 - The Core Predictors:** Velocity and user tenure are the most influential pillars within the boosting engine; km_per_hour (F score: 495) and n_days_after_onboarding (F score: 481) systematically drive the model's split decisions.
 - Recent Engagement vs. Volume:** The algorithm prioritizes highly dynamic metrics—such as recent monthly consistency (percent_sessions_in_last_month: 407) and active interactions with favorite destinations—over baseline historical accumulation factors like total driving days (driving_days: 212). This provides clear business direction for targeting retention mechanics.

ES:

- Motores de Comportamiento y Pesos Predictores
 - Los Predictores Centrales:** La velocidad y la antigüedad del usuario son los pilares más influyentes dentro del motor de potenciación; km_per_hour (F score: 495) y n_days_after_onboarding (F score: 481) dirigen sistemáticamente las decisiones de división del modelo.
 - Interacción Reciente vs. Volumen Bruto:** El algoritmo prioriza métricas altamente dinámicas—como la consistencia mensual reciente (percent_sessions_in_last_month: 407) y las interacciones activas con destinos favoritos—por encima de factores acumulativos históricos básicos como los días totales de conducción (driving_days: 212). Esto entrega una dirección de negocio clara para enfocar las mecánicas de retención.

Executive Technical Summary:WAZE

The Nuts and Bolts of Machine Learning

PACE: Execute Phase — Executive Conclusion | Fase de Ejecución — Conclusión Ejecutiva



Executive Conclusion / Conclusión Ejecutiva

EN:

- **Business Value & Operational Feasibility**
 - **Model Strategy Validation:** Based on the empirical results across the validation and final test datasets, XGBoost is selected as the definitive champion model for deployment.
 - **Operational Impact:** By shifting from a traditional parallel architecture (Random Forest) to a sequential error-correcting gradient boosting mechanism, we successfully tripled the user churn capture rate (Recall: 16.57%) while keeping false alarms at a structurally low, highly cost-effective level.
 - **Actionable ROI:** The feature importance analysis reveals that user retention campaigns should not focus on passive cumulative metrics like total driving days, but rather on real-time dynamic signals such as drop-offs in driving velocity (km_per_hour) and shifts in recent engagement (percent_sessions_in_last_month).

ES:

- **Valor de Negocio y Viabilidad Operativa**
 - **Validación de la Estrategia:** Basado en los resultados empíricos obtenidos a través de los conjuntos de validación y prueba final, XGBoost es seleccionado como el modelo campeón definitivo para su despliegue.
 - **Impacto Operacional:** Al migrar de una arquitectura paralela tradicional (Random Forest) a un mecanismo secuencial de corrección de errores por gradiente, logramos triplicar con éxito la tasa de captura de abandono (Recall: 16.57%), manteniendo las falsas alarmas en un nivel estructuralmente bajo y altamente rentable para el negocio.
 - **ROI Accionable:** El análisis de importancia de variables revela que las campañas de retención no deben centrarse en métricas pasivas acumuladas como los días totales de conducción, sino en señales dinámicas en tiempo real, tales como caídas en la velocidad de conducción (km_per_hour) y cambios en la consistencia del uso reciente (percent_sessions_in_last_month).