


Course Five

The Nuts and Bolts of Machine Learning



Instructions

Use this PACE strategy document to record decisions and reflections as you work through the end-of-course project. As a reminder, this document is a resource that you can reference in the future and a guide to help consider responses and reflections posed at various points throughout projects.

Course Project Recap

Regardless of which track you have chosen to complete, your goals for this project are:

- ☐ Complete the questions in the Course 5 PACE strategy document
- ☐ Answer the questions in the Jupyter notebook project file
- ☐ Build a machine learning model
- ☐ Create an executive summary for team members and other stakeholders


Relevant Interview Questions

Completing the end-of-course project will empower you to respond to the following interview topics:

- What kinds of business problems would be best addressed by supervised learning models?
- What requirements are needed to create effective supervised learning models?
- What does machine learning mean to you?
- How would you explain what machine learning algorithms do to a teammate who is new to the concept?
- How does gradient boosting work?

Reference Guide:

This project has seven tasks; the visual below identifies how the stages of PACE are incorporated across those tasks.



Data Project Questions & Considerations



PACE: Plan Stage

PACE: Plan Stage

What are you trying to solve or accomplish?

- **EN:** We aim to build a machine learning pipeline to predict user churn (attrition) for Waze. The operational goal is to accurately isolate at-risk users so the retention team can deploy proactive marketing strategies.
- **ES:** El objetivo es construir una infraestructura de aprendizaje automático para predecir el abandono (*churn*) de usuarios en Waze. La meta operativa es aislar con precisión a los conductores en riesgo para que el equipo de retención despliegue estrategias proactivas.

Who are your external stakeholders that I will be presenting for this project?

- **EN:** The primary stakeholders are the Waze Leadership Team, the Head of Marketing, Product Managers, and the Data Science Engineering Team.
- **ES:** Los principales interesados son el equipo de liderazgo ejecutivo de Waze, el director de marketing, los gerentes de producto y el equipo de ingeniería de ciencia de datos.

What resources do you find yourself using as you complete this stage?

- **EN:** Project scoping guidelines, Waze data dictionaries, Python workspace environments, and the structural PACE framework documentation.
- **ES:** Directrices de alcance del proyecto, diccionarios de datos de Waze, entornos de trabajo en Python y la documentación estructural del framework PACE.

Do you have any ethical considerations at this stage?

- **EN:** Yes. We must ensure user privacy through anonymization, avoid any demographic biases, and establish strict compliance rules regarding tracking user navigation logs and travel destinations.
- **ES:** Sí. Debemos garantizar la privacidad de los usuarios mediante la anonimización de datos, evitar sesgos demográficos y establecer reglas estrictas de cumplimiento sobre el rastreo de registros de navegación y destinos de viaje.

Is my data reliable?

- **EN:** Yes, the dataset is structurally robust and clean. However, it exhibits a high class imbalance (roughly 82% retained vs. 18% churned), which requires specialized machine learning architectures rather than basic linear assumptions.
- **ES:** Sí, el conjunto de datos es estructuralmente robusto y limpio. Sin embargo, presenta un fuerte desbalance de clases (aproximadamente 82% retenidos frente a 18% en abandono), lo que requiere arquitecturas especializadas de aprendizaje automático en lugar de suposiciones lineales básicas.

What data do I need/would like to see in a perfect world to answer this question?

- **EN:** Granular daily or weekly interaction logs, historical app bug/crash occurrences, explicit user satisfaction ratings (CSAT), and specific destination behavior profiles (e.g., daily work commute vs. sporadic leisure trips).
- **ES:** Registros de interacción diarios o semanales granulares, historial de fallos o cierres de la app, calificaciones explícitas de satisfacción del usuario (CSAT) y perfiles específicos de comportamiento de destino (ej. viajes diarios al trabajo frente a viajes esporádicos de ocio).

What data do I have/can I get?

- **EN:** Aggregated monthly user metrics including total driven kilometers, total sessions, driving days, activity days, and basic navigation interactions to designated favorite locations.
- **ES:** Métricas mensuales agregadas de los usuarios que incluyen kilómetros conducidos totales, sesiones totales, días de conducción, días de actividad e interacciones básicas de navegación hacia ubicaciones favoritas designadas.

What metric should I use to evaluate success of my business/organizational objective? Why?

- **EN: Recall** combined with **Precision**. Recall is paramount because missing an at-risk user (False Negative) means losing them forever, while Precision balances the financial cost of running retention campaigns on stable users (False Positives).
- **ES: Recall** combinado con **Precision**. El Recall es primordial porque omitir a un usuario en riesgo (Falso Negativo) significa perderlo para siempre, mientras que la Precisión equilibra el costo financiero de dirigir campañas de retención a usuarios estables (Falsos Positivos).

PACE: Analyze Stage

Revisit “What am I trying to solve?” Does it still work? Does the plan need revising?

- **EN:** The original core objective holds true. However, due to the high class imbalance uncovered during exploration, the plan had to be revised to include ensemble boosting architectures (XGBoost) to properly handle the data skew.
- **ES:** El objetivo central original se mantiene vigente. Sin embargo, debido al fuerte desbalance de clases descubierto durante la exploración, el plan tuvo que ser revisado para incluir arquitecturas de ensamble por potenciación (XGBoost) para manejar adecuadamente el sesgo.

Does the data break the assumptions of the model? Is that ok, or unacceptable?

- **EN:** The extreme multi-collinearity and non-linear patterns break the strict mathematical assumptions of standard Logistic Regression. This is unacceptable for linear equations but perfectly fine for tree-based ensemble models, which thrive under these complex conditions.
- **ES:** La colinealidad extrema y los patrones no lineales rompen los supuestos matemáticos estrictos de una Regresión Logística tradicional. Esto es inaceptable para ecuaciones lineales, pero perfectamente manejable para modelos de ensamble basados en árboles, los cuales prosperan bajo estas condiciones complejas.

Why did you select the X variables you did?

- **EN:** Features were selected based on behavioral engagement, frequency metrics, and distance measures (such as `km_per_hour` and `percent_sessions_in_last_month`) because they directly correlate with shifting user loyalty patterns.
- **ES:** Las variables se seleccionaron en función de la interacción del comportamiento, las métricas de frecuencia y las medidas de distancia (como `km_per_hour` y `percent_sessions_in_last_month`) porque se correlacionan directamente con los cambios en los patrones de lealtad del usuario.

What are some purposes of EDA before constructing a model?

- **EN:** To identify anomalous outliers, detect severe class imbalances, check for missing values, reveal multi-collinearity, and uncover latent distributions that determine correct model selection.
- **ES:** Identificar valores atípicos anómalos, detectar desbalances severos de clases, verificar valores faltantes, revelar la colinealidad y descubrir distribuciones latentes que determinen la selección correcta del modelo.

What has the EDA told you?

- **EN:** It revealed that churned users drive longer distances over fewer days, that app usage drops sharply for certain cohorts, and that standard features contain extreme right-skewed outliers requiring robust tree architectures.
- **ES:** Reveló que los usuarios que abandonan conducen distancias más largas en menos días, que el uso de la app cae abruptamente para ciertas cohortes y que las variables estándar contienen valores atípicos con sesgo extremo a la derecha que requieren arquitecturas de árboles robustas.

What resources do you find yourself using as you complete this stage?

- **EN:** Pandas, NumPy, Seaborn, Matplotlib, and distribution profiling libraries within Jupyter Notebook.
- **ES:** Pandas, NumPy, Seaborn, Matplotlib y librerías de perfilado de distribución dentro de Jupyter Notebook.

PACE: Construct Stage

Do I notice anything odd? Is it a problem? Can it be fixed? If so, how?

- **EN:** Extreme outliers were detected in variables like `driven_km_drives`. It is a structural pattern of heavy app users, not a bug. It was addressed naturally by using tree models, which are completely immune to monotonic scaling and outlier leverage.
- **ES:** Se detectaron valores atípicos extremos en variables como `driven_km_drives`. Es un patrón estructural de usuarios intensivos de la app, no un error. Se abordó de forma natural mediante el uso de modelos de árboles, los cuales son inmunes al escalado monotónico y al apalancamiento de valores atípicos.

Which independent variables did you choose for the model, and why?

- **EN:** We kept behavioral features including user velocity rates, activity distributions, and favorite navigation targets. We prioritized them because sequential boosting leverages these high-variance interactions to map correct churn boundaries.
- **ES:** Conservamos las variables de comportamiento, incluyendo tasas de velocidad del usuario, distribuciones de actividad y objetivos de navegación favoritos. Las priorizamos porque la potenciación secuencial aprovecha estas interacciones de alta varianza para mapear los límites correctos del abandono.

How well does your model fit the data? What is my model's validation score?

- **EN:** The Random Forest model achieved a conservative validation Recall of **5.52%**. The champion XGBoost model fit the patterns significantly better, scoring a much robust validation Recall of **17.36%** and an F1-Score of **24.82%**.
- **ES:** El modelo de Bosque Aleatorio logró un Recall de validación conservador del **5.52%**. El modelo campeón XGBoost se ajustó significativamente mejor a los patrones, alcanzando un Recall de validación mucho más robusto del **17.36%** y un F1-Score del **24.82%**.

Can you improve it? Is there anything you would change about the model?

- **EN:** Yes. We can optimize performance by adjusting the internal classification threshold down from **0.5** to a lower baseline (e.g., **0.35**) to structurally favor higher Recall rates, capturing more actual churners.
- **ES:** Sí. Podemos optimizar el rendimiento ajustando el umbral de clasificación interno por debajo de **0.5** a una línea base más baja (por ejemplo, **0.35**) para favorecer estructuralmente tasas de Recall más altas, capturando más abandonos reales.

What resources do you find yourself using as you complete this stage?

- **EN:** Scikit-Learn (**GridSearchCV**, **RandomForestClassifier**), XGBoost API (**XGBClassifier**), and training performance tables.
- **ES:** Scikit-Learn (**GridSearchCV**, **RandomForestClassifier**), la API de XGBoost (**XGBClassifier**) y tablas de rendimiento de entrenamiento.

PACE: Execute Stage

What key insights emerged from your model(s)? Can you explain my model?

- **EN:** The model functions through sequential error correction. The key insight is that user retention is driven by localized speed dynamics (**km_per_hour**) and onboarding timeline limits (**n_days_after_onboarding**), rather than simple long-term cumulative parameters.
- **ES:** El modelo funciona a través de la corrección secuencial de errores. El insight clave es que la retención de usuarios está dirigida por dinámicas de velocidad localizadas (**km_per_hour**) y límites temporales desde el registro (**n_days_after_onboarding**), en lugar de simples parámetros acumulativos a largo plazo.

What are the criteria for model selection?

- **EN:** The candidate architecture must prove structural stability between validation splits and independent test baselines, prioritizing the highest **Recall** metric without causing a catastrophic drop in **Precision**.

- **ES:** La arquitectura candidata debe demostrar estabilidad estructural entre las divisiones de validación y las líneas base de prueba independientes, priorizando la métrica de **Recall** más alta sin causar una caída catastrófica en la **Precision**.

Does my model make sense? Are my final results acceptable?

- **EN:** Yes, it makes sense. The final test metrics (**16.57% Recall** and **38.89% Precision**) are acceptable for production pilots. The tight consistency between validation and test scores mathematically confirms zero overfitting.
- **ES:** Sí, tiene sentido. Las métricas finales en el conjunto de prueba (**16.57% Recall** y **38.89% Precision**) son aceptables para pilotos de producción. La estrecha consistencia entre los puntajes de validación y prueba confirma matemáticamente que no hay sobreajuste.

Do you think your model could be improved? Why or why not? How?

- **EN:** Yes, by introducing explicit feature interactions, executing advanced oversampling methods (like SMOTE) to counteract the desbalance, or tuning probability boundaries during deployment.
- **ES:** Sí, mediante la introducción de interacciones explícitas entre variables, la ejecución de métodos avanzados de sobremuestreo (como SMOTE) para contrarrestar el desbalance o el ajuste de los límites de probabilidad durante el despliegue.

Were there any features that were not important at all? What if you take them out?

- **EN:** General baseline features such as raw **sessions** and **driving_days** scored lowest on importance. Removing them would simplify the model pipeline and speed up computation with negligible impact on final predictive power.
- **ES:** Las variables base generales como **sessions** y **driving_days** obtuvieron las puntuaciones más bajas en importancia. Eliminarlas simplificaría el flujo de procesamiento del modelo y aceleraría el cómputo con un impacto insignificante en el poder predictivo final.

What business/organizational recommendations do you propose based on the models built?

- **EN:** Target low-cost retention interventions (like push notifications) to users triggering micro-drops in monthly consistency or exhibiting distinct speed profiles, avoiding expensive marketing spend on false alarms.
- **ES:** Dirigir intervenciones de retención de bajo costo (como notificaciones push) a usuarios que presenten microcaídas en su consistencia mensual o muestren perfiles de velocidad distintos, evitando gastos costosos de marketing en falsas alarmas.

Given what you know about the data and the models you were using, what other questions could you address for the team?

- **EN:** We could explore user lifetime value (LTV) models or predict which specific alternative navigation features might win back an at-risk user before they fully churn.
- **ES:** Podríamos explorar modelos de valor de vida del usuario (LTV) o predecir qué características alternativas de navegación específicas podrían recuperar a un usuario en riesgo antes de que abandone por completo.

What resources do you find yourself using as you complete this stage?

- **EN:** `ConfusionMatrixDisplay`, feature importance weight plotting tools, bilingually compiled technical briefs, and presentation summary slide decks.
- **ES:** `ConfusionMatrixDisplay`, herramientas de graficación de pesos de importancia de variables, resúmenes técnicos compilados de forma bilingüe y diapositivas de presentación ejecutiva.

Is my model ethical?

- **EN:** Yes, because it relies strictly on anonymized behavior logs (`km_per_hour`, `sessions`). It does not integrate protected personal traits, and its classification error does not negatively restrict user rights.
- **ES:** Sí, porque se basa estrictamente en registros de comportamiento anonimizados (`km_per_hour`, `sessions`). No integra características personales protegidas y su error de clasificación no restringe negativamente los derechos de los usuarios.

When my model makes a mistake, what is happening? How does that translate to my use case?

- **EN:** A False Positive targets a stable user with an unnecessary push message. A False Negative misses a real churner, leaving them to leave Waze. Given our use case, False Positives are low-risk and economically safe.
- **ES:** Un Falso Positivo dirige un mensaje push innecesario a un usuario estable. Un Falso Negativo omite a un usuario en abandono real, permitiendo que deje Waze. Dado nuestro caso de uso, los Falsos Positivos son de bajo riesgo y económicamente seguros.